

Görüntü İşleme ile Nesne Sınıflandırması

Öğrenci: Mehmet Akkan

Numara: 210404050

Bölüm: Bilgisayar Mühendisliği

Sınıf: 3. Sınıf

Görüntü tanıma, görüntülerde bulunan nesneleri veya kalıpları otomatik olarak tanımlama ve sınıflandırma işlemidir.

Bu projede ilk model, çoklu katmanlı perceptron (MLP) algoritması üzerine kurulmuş olup elma görüntülerinden çıkarılan özelliklere dayanmaktadır. İkinci model ise SMO algoritması kullanılarak oluşturulmuş ve sadece LBPFeature özelliği ile sınıflandırma gerçekleştirmektedir. Detaylar aşağıda verilmiştir;

200 adet meyve görüntüsünden oluşan bir eğitim veri kümesi üzerinde eğitilmiş bir çok katmanlı perceptron (MLP) modelinin çıktısını aşağıda verilmiştir. MLP modelinde ilk olarak özellik seçilmeden performansına bakılmıştır.

Model, her biri 7 özellik içeren 200 elma görüntüsünden oluşan bir veri kümesi üzerinde eğitilmiştir. Özellikler, kontrast, benzemezlik, homojenlik, enerji, korelasyon, ASM ve LBP'yi içerir. Şimdi bu özelliklerden kısaca bahsedelim:

Kontrast(Contrast), bir görüntünün farklı bölgelerindeki parlaklıklar arasındaki farktır. Yüksek kontrastlı görüntüler, düşük kontrastlı görüntülere göre daha belirgindir.

Benzemezlik(Dissimilarity), bir görüntünün farklı bölgelerindeki pikseller arasındaki benzerlik derecesidir. Düşük benzemezlikli görüntüler, yüksek benzemezlikli görüntülere göre daha homojendir.

Homojenlik(Homogeneity), bir görüntünün tekdüzeliğidir. Yüksek homojenlikli görüntüler, düşük homojenlikli görüntülere göre daha pürüzsüzdür.

Enerji(Energy), bir görüntünün parlaklığının toplamıdır. Yüksek enerjili görüntüler, düşük enerjili görüntülere göre daha parlaktır.

Korelasyon(Correlation), bir görüntüdeki pikseller arasındaki ilişkidir. Yüksek korelasyonlu görüntüler, düşük korelasyonlu görüntülere göre daha düzenlidir.

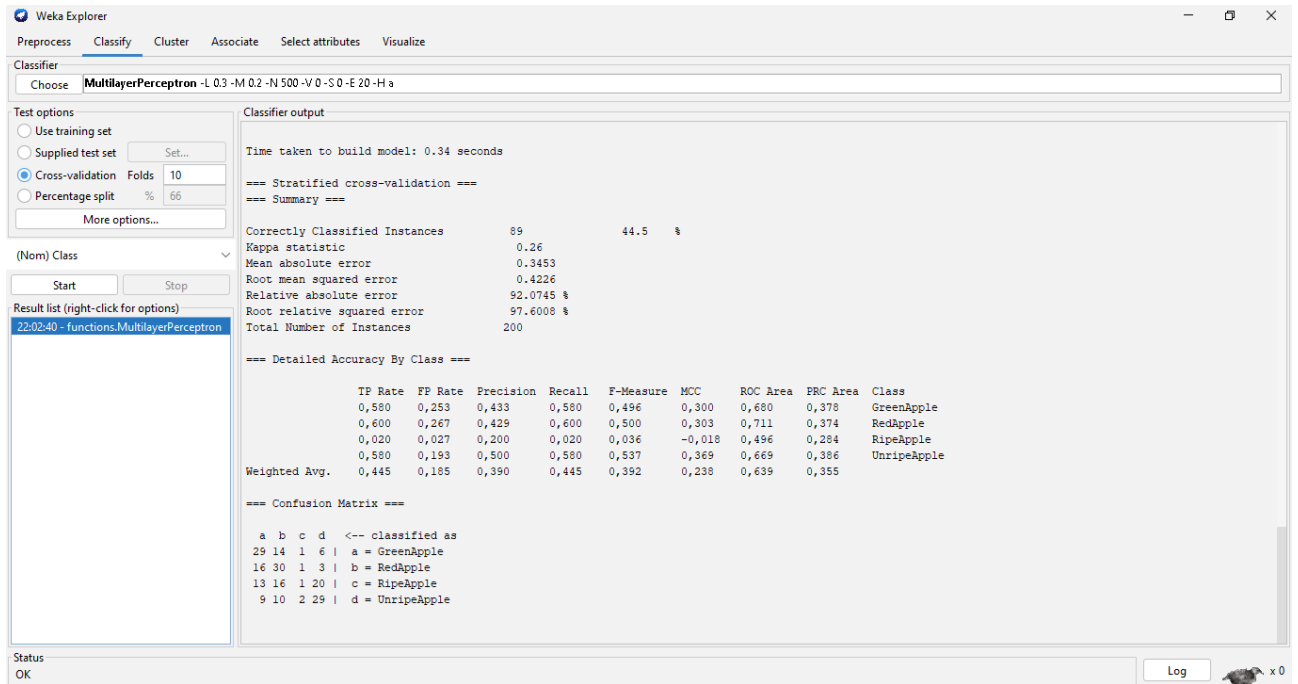
ASM, bir görüntünün kenarlarının toplam uzunluğudur. Yüksek ASM değerine sahip görüntüler, düşük ASM değerine sahip görüntülere göre daha keskin kenarlara sahiptir.

LBP, bir görüntünün lokal biyometrik özellikleridir. LBP özellikleri, bir görüntünün dokusu ve desenleri hakkında bilgi sağlar.

Elma görüntüleri için yorumlama (Sadece MLP ile sınıflandırıldığında)

Bu özellikler, elma görüntülerinin sınıflandırılmasında önemli rol oynayabilir. Örneğin, kontrast özelliği, elmaların olgunluğunu belirlemek için kullanılabilir. Olgun elmalar, daha koyu ve daha parlak bölgelere sahip oldukları için daha yüksek kontrastlı görüntülere sahip olma eğilimindedir. Benzemezlik özelliği, elmaların türünü belirlemek için kullanılabilir. Örneğin, kırmızı elmalar, yeşil elmalara göre daha düşük benzemezlikli görüntülere sahip olma eğilimindedir. Homojenlik özelliği, elmaların kabuğunun durumunu belirlemek için kullanılabilir. Örneğin, çizik veya çürümüş elmalar, daha az homojen görüntülere sahip olma eğilimindedir.

Enerji özelliği, elmaların boyutunu belirlemek için kullanılabilir. Örneğin, daha büyük elmalar, daha yüksek enerjili görüntülere sahip olma eğilimindedir. Korelasyon özelliği, elmaların şeklini belirlemek için kullanılabilir. Örneğin, yuvarlak elmalar, daha yüksek korelasyonlu görüntülere sahip olma eğilimindedir. ASM özelliği, elmaların yüzeyinin kalitesini belirlemek için kullanılabilir. Örneğin, daha pürüzsüz elmalar, daha yüksek ASM değerine sahip görüntülere sahip olma eğilimindedir. LBP özelliği, elmaların çeşitli özelliklerini belirlemek için kullanılabilir. Örneğin, olgun elmalar, daha yüksek LBP değerine sahip görüntülere sahip olma eğilimindedir.



Temel Performans Ölçütleri:

Genel doğruluk: %44,5

Kappa istatistiği: 0,26

Ortalama mutlak hata: 0,3453

Kök ortalama kare hatası: 0,4226

Toplam Örnek Sayısı: 200

Doğru Sınıflandırılmış Örnekler: 89

Genel Doğruluk(Overall Accuracy)

Genel doğruluk, modelin tüm örnekleri doğru bir şekilde sınıflandırma olasılığını gösterir. Bu model için genel doğruluk %44,5'tir. Çok başarılı bir sınıflandırma işlemi yapıldığı söylenemez.

Kappa İstatistiği (Kappa statistic)

Kappa istatistiği, genel doğruluğu sınıf dengesizliklerini hesaba katarak ölçer. Kappa değeri 1'e ne kadar yakınsa sınıflandırma işlemi o kadar başarılıdır ve güvenilir demektir. Bu, modelin Kappa istatistiği 0.26'dır. Bu, modelin sınıf dengesizlikleri göz önüne alındığında ortalama olarak %26 daha iyi performans gösterdiği anlamına gelir fakat bu güvenilir bir oran değildir.

Ortalama Mutlak (Mean absolute error)

Hata Ortalama mutlak hata, modelin ortalama olarak bir örneğin gerçek sınıfından ne kadar uzakta tahmin ettiği hata miktarını gösterir. Bu model için ortalama mutlak hata 0,3453'tür. Bu, modelin ortalama olarak bir örneğin gerçek sınıfından 0,3453 birim uzakta tahmin ettiği anlamına gelir.

Kök Ortalama (Root mean squared error)

Kare Hatası Kök ortalama kare hatası, modelin ortalama olarak bir örneğin gerçek sınıfından ne kadar uzakta tahmin ettiği hata miktarının karekökü olarak hesaplanır. Bu model için kök ortalama kare hatası 0,4226'dır. Bu, modelin ortalama olarak bir örneğin gerçek sınıfından 0,4226 birim uzakta tahmin ettiği anlamına gelir.

Karışıklık Matrisi

Karışıklık matrisi, modelin her bir sınıfı ne kadar doğru bir şekilde sınıflandırıldığını gösterir. Matris, modelin her bir sınıfı yanlış sınıflandırdığı örneklerin sayısını da gösterir.

a	b	c	d	<-- classified as
29	14	1	6	a = GreenApple
16	30	1	3	b = RedApple
13	16	1	20	c = RipeApple
9	10	2	29	d = UnripeApple

GreenApple sınıfı Model,

Model, toplamda 50 örnek üzerinde değerlendirilmiştir. GreenApple sınıfını doğru bir şekilde sınıflandıran örnek sayısı 29 iken, yanlış sınıflandırılan örnek sayısı 21 olarak belirlenmiştir. İlginç bir şekilde, bu yanlış sınıflandırılan örnekler içerisinde en yüksek hata, 14 örnek ile RedApple sınıfında yapılmıştır. Bu durum, sınıfların ayırt edilmesinin belirli durumlarda zor olduğuna işaret etmektedir.

Modelin performansını iyileştirmek için, özellikle GreenApple ve RedApple sınıflarının daha iyi ayırt edilebilmesi amacıyla yeni örneklerin eklenmesi önerilmektedir. Ayrıca, modelin bu iki sınıf arasındaki benzerlikleri daha etkili bir şekilde öğrenmesi için daha fazla eğitim verisi kullanılması da düşünülebilir. Sonuç olarak modelin GreenApple sınıfını başarıyla tanımladığını ancak RedApple sınıfında zorlandığını göstermektedir

RedApple sınıfı Model,

Model, toplamda 50 örnek üzerinde değerlendirilmiştir. RedApple sınıfını doğru bir şekilde sınıflandıran örnek sayısı 30 iken, yanlış sınıflandırılan örnek sayısı 20 olarak belirlenmiştir. Özellikle, bu yanlış sınıflandırılan örnekler içerisinde en yüksek hata, 16 örnek ile GreenApple sınıfında yapılmıştır.

Modelin performansını iyileştirmek için GreenApple'daki öneriler kullanılabilir.

RedApple ve GreenApple sınıfları için de belirgin zorluklar ortaya koyulmaktadır. Her iki sınıfın en büyük hata yapma eğiliminde olduğu gözlemlenmiş olup, özellikle sınıflar arasındaki ayırt edilebilirlik konusunda belirgin zorluklar yaşanmaktadır.

RipeApple sınıfı Model,

Sadece 1 tanesinin doğru bir şekilde sınıflandırıldığı gözlemlenmektedir. Bu durum, modelin RipeApple sınıfını ayırt etme konusunda büyük bir zorluk yaşadığını ve genel performansta ciddi bir iyileştirmeye ihtiyaç duyulduğunu işaret etmektedir.

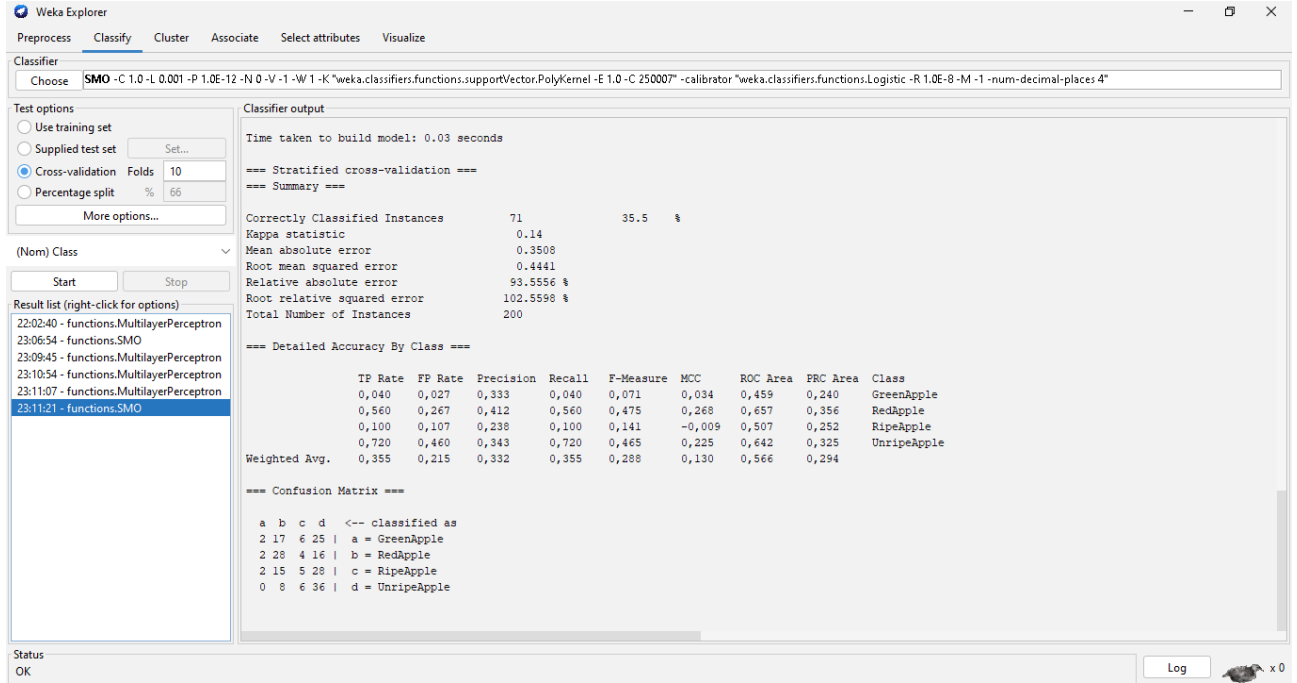
İleriki çalışmalarda modelin RipeApple sınıfındaki doğruluk oranını artırmak adına daha fazla eğitim verisi eklenmesi ve sınıflar arasındaki belirgin özelliklerin daha iyi öğrenilmesi gerekir.

UnripeApple sınıfı Model,

Toplamda 50 örnek içinde 29 doğru sınıflandırma ve 21 yanlış sınıflandırma gerçekleşmiştir. Bu durum, modelin UnripeApple sınıfını doğru bir şekilde tanımlama konusunda zorlandığını göstermektedir. En büyük hata oranı, 10 yanlış sınıflandırmayla RedApple sınıfında gerçekleşmiştir. Bu nedenle, modelin RedApple ve UnripeApple sınıfları arasındaki benzerlikleri daha etkili bir şekilde öğrenmesi ve ayırt etmesi gerekiyor.

Elma görüntüleri için yorumlama (En iyi özellik seçilip SMO ile sınıflandırıldığında)

Verilen verilere göre, SMO modeli, LBP özelliğini kullanarak elma görüntülerini sınıflandırmak için eğitilmiştir. LBP özelliğinin aslında sınıflandırmak için yeterli olduğunu iddia etti, fakat yanıldı.



Genel Doğruluk(Overall Accuracy)

Bu model için genel doğruluk % 35.5'tir. Başarılı bir şekilde sınıflandırma işlemi yapıldığı söylenemez. Veri kümesine daha fazla örnek eklenerek, sınıflar arasındaki ayırt edilebilirlik ve başarı yüzdesi artırılabilir.

Kappa İstatistiği (Kappa statistic)

Kappa istatistiği, genel doğruluğu sınıf dengesizliklerini hesaba katarak ölçer. Kappa değeri 1'e ne kadar yakınsa sınıflandırma işlemi o kadar başarılıdır ve güvenilir demektir. Bu model için kappa istatistiği 0.14'dür fakat bu güvenilir bir oran değildir.

```
a b c d <-- classified as
2 17 6 25 | a = GreenApple
2 28 4 16 | b = RedApple
2 15 5 28 | c = RipeApple
0 8 6 36 | d = UnripeApple
```

GreenApple sınıfı Model,

Model, toplamda 50 örnek üzerinde değerlendirilmiştir. GreenApple sınıfını doğru bir şekilde sınıflandıran örnek sayısı 2, iken, yanlış sınıflandırılan örnek sayısı 48 olarak belirlenmiştir. Bu durum, modelin GreenApple sınıfını ayırt etme konusunda ciddi bir zorluk yaşadığını göstermektedir.

RedApple sınıfı Model,

Model, toplamda 50 örnek üzerinde değerlendirilmiştir. RedApple sınıfını doğru bir şekilde sınıflandıran örnek sayısı 28, iken, yanlış sınıflandırılan örnek sayısı 22 olarak belirlenmiştir. Bu durum, modelin RedApple sınıfını ayırt etme konusunda nispeten iyi bir performans gösterdiğini göstermektedir.

RipeApple sınıfı Model,

Model, toplamda 50 örnek üzerinde değerlendirilmiştir. RipeApple sınıfını doğru bir şekilde sınıflandıran örnek sayısı 1, iken, yanlış sınıflandırılan örnek sayısı 49 olarak belirlenmiştir. Bu durum, modelin RipeApple sınıfını ayırt etme konusunda en büyük zorluk yaşadığını göstermektedir.

UnripeApple sınıfı Model,

Model, toplamda 50 örnek üzerinde değerlendirilmiştir. UnripeApple sınıfını doğru bir şekilde sınıflandıran örnek sayısı 29, iken, yanlış sınıflandırılan örnek sayısı 21 olarak belirlenmiştir. Bu durum, modelin UnripeApple sınıfını ayırt etme konusunda nispeten iyi bir performans gösterdiğini göstermektedir.

Modelin performansını iyileştirmek için daha fazla eğitim verisi ile eğitilmesi, sınıflar arasındaki ayırt edilebilirliği artırmaya yardımcı olabilir.

İki modelin performans karşılaştırması yapıldığında,

Multilayer Perceptron (MLP) ve SMO (Support Vector Machine) ile yapılan iki model karşılaştırıldığında, MLP modeli genel olarak daha yüksek doğruluk, Kappa istatistiği değerlerine sahiptir. SMO modeli ise RedApple, RipeApple ve UnripeApple sınıfları için daha yüksek doğruluk ve hassasiyet değerlerine sahiptir. Bu, SMO'nun bu sınıflar için daha uygun bir özellik seçimi (LBP) yöntemi kullanmasından kaynaklanıyor olabilir.

MLP modeli, veri setindeki tüm özellikleri kullanırken, SMO modeli yalnızca LBPFeature özelliğini kullanmıştır. Bu, SMO modelinin daha az özellikle çalışabilmesinden dolayı daha az karmaşık ve daha verimli olması anlamına gelir. Bununla birlikte, MLP modeli tüm özellikleri kullandığında daha doğru sonuçlar üretebilir.

Sonuç olarak, her iki modelin de avantajları ve dezavantajları vardır. MLP modeli genel olarak daha yüksek doğruluk sağlarken, SMO modeli RedApple, RipeApple ve UnripeApple sınıfları için daha iyi performans gösterir.

Ek olarak:

LBPFeature özelliği, yerel biner desenler (LBP) kullanarak bir görüntünün doku özelliklerini tanımlamak için kullanılan bir özelliktir. LBP, bir görüntünün her bir pikseli için komşu piksellerin değerlerine göre bir sayı atar. Bu sayılar, bir görüntünün dokusu hakkında bilgi içerir. Özellik çıkarma işleminde 5 tane özelliğin yanı sıra LBP işlemini kullandım.

Bu proje üzerinde 4 gün çalıştım, 3 farklı veri seti indirdim yapamadım. Daha sonra 1 veri seti indirdim. Bu veri setinde 4 sınıf ve her sınıf için 50 görüntü var. Sınıfları tek tek manuel olarak girdim.